

AI安全与伦理系列

负责任的AI发展

AI技术专栏

2026年

目录

1. AI安全与伦理系列 01
2. AI安全与伦理系列 02
3. AI安全与伦理系列 03
4. AI安全与伦理系列 04
5. AI安全与伦理系列 05
6. AI安全与伦理系列 06
7. AI安全与伦理系列 · 总结

1. AI安全与伦理系列 01

AI安全与伦理系列 01 · AI幻觉

AI安全与伦理系列 01

系列一

AI幻觉：为什么AI会“胡说八道”？

我的观点：

2026年的今天，AI的幻觉问题已经比三年前改善了很多——简单的事实错误已经很少见了。但幻觉并没有消失，只是变得更隐蔽、更难发现了。理解幻觉的本质，不是为了消除它（或许永无法完全消除），而是为了学会识别它，在关键问题上保持警惕。

一个真实的案例

2025年，一位研究人员用主流AI写论文综述。

AI引用了十几篇看起来很权威的参考文献。

结果发现：有3篇论文的细节是编造的！

这些论文的标题、作者看起来都很真实，甚至还有DOI编号——但实际上，论文里讨论的具体方法和结果是AI编的。

这就是2026年的幻觉新形式：

不是编造整个事实，而是在真实的框架里编造细节。简单的问题AI已经很少错了，但复的、需要交叉验证的问题，AI还是可能会“补全”一些看起来合理但实际不存在的信息。

1

什么是AI幻觉？

AI幻觉（Hallucination）是指AI生成看似合理但实际上是错误、编造或没有根据的内容。

2026年幻觉的新表现：

1.

细节编造

：在真实框架里编造细节（比如真实论文里编造实验结果）

2.

逻辑跳跃

：看似合理但实际不成立的推理链

3.

虚假权威

：编造专家说法或研究结论

4.

数据伪造

：编造看起来很真实的统计数据

5.

来源混淆

：把A说过的话安在B身上

2026年的幻觉更隐蔽了：简单的事实（比如"杨利伟有没有登月"）AI已经很少错，但复的、需要交叉验证的内容，AI还是可能会"补全"一些看起来合理但实际不存在的细节。

2025年的真实案例

用户问："2024年北京市AI产业规模是多少？"

AI回答："根据北京市经信局2025年1月发布的报告，2024年北京市AI产业规模达到4872亿元，同比增长32.6%。其中，核心产业规模1568亿元，同比增长28.3%。主要增长来自生成式AI应用的爆发。"

事实：这些数字看起来非常真实，有零有整，还有来源——但实际上是编的。北京市确实发布过AI产业报告，但数字完全不同。这就是现代幻觉：不是乱编，而是编得像真的。

2

2026年了，为什么还有幻觉？深度分析

虽然技术进步很大，但幻觉并没有完全消失。原因在于：

原因一：大模型依然是"预测机器"

本质上，AI还是在预测下一个token，而不是真正"知道"事实。对于常见的事实（如"杨利伟有没有登月"），训练数据里重复了成千上万次，AI很难错。但对于复、不常见的细节，AI还是会根据统计规律"补全"信息。

技术细节：

Transformer的注意力机制只能捕捉训练数据中的统计关联，无法建立真正的因果理解。当遇到训练数据中没

有明确答案的问题时，它会根据上下文"猜测"最可能的答案。

原因二：知识有截止日期

2026年的模型可能只训练到2025年中的数据，对于之后发生的事情，AI只能猜测。而且即使是训练数据里有的内容，也不一定完全准确。

技术细节：

大多数大模型都有"知识截止日期"（Knowledge Cutoff），这是训练数据的最后日期。OpenAI的GPT-5截止到2025年3月，Google的Gemini 2.0截止到2025年6月。

原因三："看起来合理"与"事实准确"的平衡

如果AI只说"我不知道"，那它就没用了。如果AI太敢说，又会产生幻觉。这是一个产品权衡——几乎所有产品都会让AI在不确定的时候尽量给出一个"合理"的答案。

技术细节：

这涉及到模型的"温度"参数。温度越高，模型越"敢说"，创造力越强，但幻觉也越多。大多数消费级AI产品的温度设置在0.7左右，这是一个平衡点。

原因四：RAG也不是万能的

虽然RAG（检索增强生成）可以显著减少幻觉，但它也有局限性：检索到的信息可能不准确、过时，或者模型可能错误地使用检索到的信息。

技术细节：

RAG的效果取决于检索质量和重排序算法。如果检索到的文档与问题不相关，或者模型在生成时错误地引用了文档内容，仍然会产生幻觉。

3

2026年的防幻觉技术：深度解析

技术已经进步了很多，现在主流的方法有：

防幻觉技术体系：

1.

检索增强生成(RAG)

：最常用的方法，通过检索外部知识库来增强回答的准确性

2.

思考链(CoT)

：让模型分步思考，减少逻辑跳跃

3.

事实检查(Fact-Checking)

：生成后自动验证关键事实

4.

不确定性量化

：让模型评估自己答案的置信度

5.

模型对齐

：通过RLHF训练模型更诚实

深度解析：现代RAG的工作方式

2026年的RAG流程

1. 用户提问："2024年北京市AI产业规模"
2. 系统进行语义检索，从向量数据库中找到相关文档
3. 使用重排序模型（如CrossEncoder）对检索结果排序
4. 将前3-5篇文档作为上下文输入给大模型
5. 模型基于上下文生成回答，并引用来源

技术细节：

现代RAG使用向量数据库（如Pinecone、Weaviate）存储文档向量，使用Sentence-BERT或E5等模型生成向量。重排序步骤非常重要，可以显著提高检索准确率。

思考链(CoT)的原理

思考链让模型先"思考"再回答。例如，当问"2024年中国GDP是多少？"时，模型会先回想："中国GDP数据通常由国家统计局发布"→"2024年的数据应该在2025年初发布"→"我需要查找最新的官方数据"。

技术细节：

CoT通过在prompt中加入"让我一步步思考"等指令实现。2025年后，很多模型在训练时就已经融入了CoT能力。

4

2026年，我们如何使用AI更安全？

虽然AI进步了，但我们还是需要保持警惕：

2026年的实用建议：

1.

看来源

：优先使用有检索来源的回答

2.

交叉验证

：关键信息多方验证

3.

索要过程

：让AI"一步步思考"并展示过程

4.

分层信任

：娱乐内容可以放松，高风险场景（医疗、法律、投资）必须小心

5.

注意"不确定"标识

：很多AI现在会表明自己不确定

2026年的实用Prompt

简单提问："2024年北京AI产业规模"

更好的提问："2024年北京AI产业规模？请先查找权威来源，引用来源，然后回答。如果不确定，请说明。"

更好的做法：直接在有内置RAG的产品里提问，比如New Bing、Claude的联网模式、或者各种知识库产品。

5

深度思考：幻觉与创造力的平衡

有趣的是：幻觉和创造力是硬币的两面。

创造力 vs 准确性

如果你想让AI写小说、编故事、头脑风暴，你需要它有一定的"幻觉"能力——不然写出来的东西就太无趣了。

但如果你想让AI回答事实问题、写代码、做数学题，你就需要它完全准确。

这是一个永恒的矛盾：完全消除幻觉，可能就消除了AI的创造性。

这个矛盾没有完美答案。关键在于：根据场景选择合适的平衡点。

6

总结：2026年，与AI共处

核心结论：

1. 2026年的AI已经很少犯简单的事实错误了
2. 但幻觉没有消失，只是变得更隐蔽、更难发现
3. 关键是识别什么时候需要警惕：复问题、高风险场景、需要精确数据的情况
4. 现代工具（RAG、思考链、事实检查）已经能帮上很大忙
5. 分层信任：根据场景决定信任程度

2023年的问题是"AI会不会错"，2026年的问题是"什么时候需要警惕"。AI进步了，但我们的警惕心也应该同步提升。

系列一：AI安全与伦理系列

01 · AI幻觉：为什么AI会“胡说八道”？ ← 你在这里

02 · 数据隐私：你的对话被用来训练了吗？

03 · AI偏见：算法歧视是怎么产生的？

04 · 深度伪造：如何识别AI生成的内容？

05 · AI安全：对抗攻击与防御

06 · 伦理困境：AI决策的责任归属

系列总结

2. AI安全与伦理系列 02

AI安全与伦理系列 02 · 数据隐私

AI安全与伦理系列 02

系列一

数据隐私：你的对话被用来训练了吗？

我的观点：

2026年，数据隐私问题已经有了很大改善——大多数主流AI服务现在都默认不使用用户对话训练模型了。但隐私风险并没有消失，只是变得更隐蔽了。我们需要关注的不再是"数据是否被收集"，而是"数据如何被使用"。

2026年的新问题

2025年底，一家AI公司推出了"个性化模型"服务：

根据你的使用习惯，为你定制专属模型！

听起来很棒，但背后有什么问题？

问题在于：

为了定制你的模型，AI需要持续分析你的对话、偏好、甚至情绪。虽然这些数据不会用来训练通用模型，但它们会被用来"微调"你的专属模型——这意味着你的数据被永久保存，并且可能被用来分析你的行为模式。

1

2026年的数据使用方式

2026年，主流AI服务的隐私政策已经变得更加透明：

2026年的数据用途：

1.

即时推理

：数据只在内存中临时处理，不保存

2.

个性化体验

：保存你的偏好设置（如主题、语言）

3.

服务改进（可选）

：需要明确同意才能用于训练

4.

安全审计

：为了检测恶意使用，可能保存一段时间

5.

商业化用途

：在匿名化后可能用于市场分析

好消息是：现在大多数服务都默认关闭了"用我的数据改进服务"选项。

2

2026年的新隐私风险

虽然基础隐私保护做得更好了，但新的风险也在出现：

2025年案例：模型"记住"了用户数据

2025年，一位用户发现：当他用某AI写代码时，AI居然生成了他公司内部代码库的片段！

原来，他之前上传过公司代码让AI帮他分析。虽然他删除了对话，但模型已经"记住"了这些代码。

这就是2026年的新风险：模型可能在推理过程中"记住"并泄露你的数据。

2026年的新隐私风险：深度分析

1.

模型记忆

：大模型可能在生成时"回忆"起训练数据中的隐私信息。

技术细节：

这是因为大模型的注意力机制会记住训练数据中的模式，当输入与训练数据中的隐私信息相似时，可能会生成相关内容。

2.

向量数据库泄露

：RAG系统使用的向量数据库可能泄露。

技术细节：

向量数据库存储了文档的语义向量，如果数据库被攻击，攻击者可以通过向量重建原始文档内容。

3.

个性化追踪

：为了提供个性化服务，你的行为被持续分析。

技术细节：

很多服务会构建用户画像，包括你的偏好、兴趣、甚至情绪状态。

4.

第三方插件

：AI插件可能在你不知情的情况下收集数据。

技术细节：

插件通常需要访问你的对话历史，有些插件可能会将数据发送到第三方服务器。

5.

数据残留

：即使删除对话，数据可能仍在缓存或备份中。

技术细节：

数据可能存在于内存缓存、磁盘缓存、日志文件、备份等多个地方。

3

2026年的隐私保护实践

作为用户，你可以做这些事来保护自己的隐私：

做法

说明

难度

检查隐私设置

定期检查AI服务的隐私设置，确保数据收集是你想要的

简单

使用隐私模式

大多数服务都有"无痕模式"或"临时对话"功能

简单

谨慎使用插件

只安装信任的插件，注意插件的权限

中等

数据脱敏

在发送敏感信息前，先删除个人信息

简单

使用企业版

企业版通常有更严格的数据隔离

中等

自托管模型

对于高度敏感场景，可以自己部署模型

困难

实用技巧：如何设置不收集数据

设置步骤

大多数AI服务都有这个选项，通常在：

设置 → 隐私 → 数据收集和改进服务

勾选"不使用我的数据来改进服务"。虽然这可能会让模型改进得慢一点，但你的隐私更安全。

4

技术层面的隐私保护：深度解析

除了用户层面的保护，技术上也有很多方法：

差分隐私(Differential Privacy)

原理：

在数据中加入随机噪声，使得无法确定任何单个个体的数据是否被包含在数据集中。

应用：

Google、Apple等公司在用户数据分析中广泛使用差分隐私。例如，当统计用户行为模式时，会在结果中加入噪声，保护个人隐私。

技术细节：

差分隐私有严格的数学定义，通常用 ϵ （隐私预算）来衡量保护程度， ϵ 越小，保护越强，但数据可用性越低。

联邦学习(Federated Learning)

原理：

数据留在用户设备本地，只传输模型更新（梯度）到服务器，服务器聚合更新后再分发回设备。

应用：

Google的Gboard键盘、Apple的Siri都使用联邦学习来改进模型，同时保护用户隐私。

技术细节：

联邦学习使用安全聚合（Secure Aggregation）技术，确保服务器无法还原单个用户的梯度。

加密计算(Homomorphic Encryption)

原理：

在加密状态下对数据进行计算，无需解密即可得到加密的结果。

应用：

医疗数据共享、金融数据分析等场景。

技术细节：

全同态加密（FHE）是最强大的形式，可以进行任意计算，但计算开销很大。目前常用的是部分同态加密。

5

深度思考：隐私的新定义

2026年，我们对隐私的理解也在变化：

隐私的新平衡

过去，隐私意味着"我的数据不被收集"。

现在，隐私意味着"我的数据如何被使用，由我决定"。

完全不收集数据的AI是不存在的——关键在于：数据的使用是否透明、是否可控、是否有明确的边界。

我的建议是：了解你的数据去向，但也不要过度焦虑——2026年的隐私保护已经比三年前好太多了。

总结：2026年的数据隐私

核心结论：

1. 2026年，主流AI服务已经默认不使用用户数据训练模型了
2. 但新的风险在出现：模型记忆、向量数据库、第三方插件
3. 定期检查隐私设置，谨慎使用插件
4. 技术已经进步很多，不必过度焦
5. 隐私的关键是"透明"和"可控"

系列一：AI安全与伦理系列

- 01 · AI幻觉：为什么AI会“胡说八道”？
- 02 · 数据隐私：你的对话被用来训练了吗？ ← 你在这里
- 03 · AI偏见：算法歧视是怎么产生的？
- 04 · 深度伪造：如何识别AI生成的内容？
- 05 · AI安全：对抗攻击与防御
- 06 · 伦理困境：AI决策的责任归属

系列总结

3. AI安全与伦理系列 03

AI安全与伦理系列 03 · AI偏见

AI安全与伦理系列 03

系列一

AI偏见：算法歧视是怎么产生的？

我的观点：

2026年，AI偏见问题已经得到了很大改善——大多数主流AI服务都已经建立了偏见检测和缓解机制。但偏见并没有消失，它只是变得更隐蔽了。我们需要关注的不再是"明显的歧视"，而是"微妙的、系统性的不公平"。

2025年的新案例

2025年，某AI贷款审批系统被发现：

来自某些地区的申请人更容易被拒绝！

为什么会这样？

因为AI学习了地区和还款率之间的统计关联。

虽然AI没有直接歧视地域，但它学到了"某些地区的人还款率更低"的模式——这就是2026年的偏见：不是直接的歧视，而是通过间接的特征关联表现出来。

1

AI偏见的表现形式

AI偏见可以表现在很多方面：

常见的偏见类型：

1.

性别偏见

：认为某些职业更适合某一性别

2.

种族偏见

：对不同种族的人区别对待

3.

年龄偏见

：认为年轻人更聪明，或者年龄大的人不行

4.

地域偏见

：对某个地区的人有刻板印象

5.

其他偏见

：外貌、学历、名字.....

2025年的新案例：大模型的"刻板印象"

2025年的一项研究发现：

当要求大模型描述"程序员"时，它倾向于描述年轻男性的特征；

当要求描述"领导"时，它倾向于描述年长男性的特征。

这不是因为模型有恶意，而是因为训练数据里这些职业的人群分布就是这样的。

2

偏见从哪里来？

AI偏见不是凭空产生的，主要有这几个来源：

来源

说明

示例

训练数据

数据里本身就有偏见

历史上某些地区的贷款违约率高

采样偏差

数据采样不具有代表性

面部识别训练数据年轻人多

标签偏差

数据标签里有偏见

给某些职业标签更多关联年轻人

算法设计

算法本身可能放大偏见

某些特征权重设置不合理

关键理解：AI是镜子，不是窗户

AI不是在"发现"客观真理，而是在"反映"训练数据里的模式。

如果训练数据里有偏见，AI就会学到偏见，而且放大偏见——因为AI只会做统计规律，不会理解"这不公平"。

3

2026年的偏见缓解技术：深度解析

2026年，已经有很多成熟的技术来减少偏见：

去偏数据预处理

原理：

在训练前检测并修正数据中的偏见。

方法：

- 数据审计：使用统计方法检测不同群体在数据中的分布差异
- 重采样：对代表性不足的群体进行过采样，或对代表性过高的群体进行欠采样
- 生成合成数据：使用GAN生成平衡的训练数据

技术细节：

常用的指标包括人口统计平等（Demographic Parity）、均等机会（Equalized Odds）等。

公平约束训练

原理：

在模型训练过程中加入公平性约束，使模型在准确性和公平性之间取得平衡。

方法：

- 对抗去偏：训练一个别器来检测预测中的偏见，同时训练主模型来对抗它

- 正则化方法：在损失函数中加入公平性正则项

- 预处理+训练联合优化

技术细节：

常用的约束包括：差异影响约束、平等机会约束、校准约束等。

偏见检测工具

原理：

自动检测模型输出中的偏见模式。

方法：

- 统计分析：分析不同群体的预测结果分布
- LLM评估：使用大模型评估输出是否存在偏见
- 敏感属性探测：检测模型是否使用了不应使用的敏感特征

技术细节：

Google的AI Fairness Toolkit、IBM的AI Fairness 360都是常用的工具。

4

深度思考：什么是"公平"？

这是一个复的问题：

公平的不同定义

1.

结果公平

：不同群体的录取率相同

2.

机会公平

：同样的能力得到同样的结果

3.

过程公平

：同样的规则适用于所有人

这三个目标往往无法同时满足！比如，为了结果公平，可能需要对不同群体设不同分数线，但这又违反了过程公平。

没有完美的答案，但我们至少要意识到这些问题的存在。

5

总结：2026年的AI偏见

核心结论：

1. 2026年，明显的AI偏见已经很少见了
2. 但微妙的、间接的偏见依然存在
3. 偏见的根源仍然是训练数据中的社会偏见
4. 现在有成熟的技术来检测和缓解偏见
5. 最终还是要靠人来定义和实现"公平"

系列一：AI安全与伦理系列

01 · AI幻觉：为什么AI会“胡说八道”？

02 · 数据隐私：你的对话被用来训练了吗？

03 · AI偏见：算法歧视是怎么产生的？ ← 你在这里

04 · 深度伪造：如何识别AI生成的内容？

05 · AI安全：对抗攻击与防御

06 · 伦理困境：AI决策的责任归属

系列总结

4. AI安全与伦理系列 04

AI安全与伦理系列 04 · 深度伪造

AI安全与伦理系列 04

系列一

深度伪造：如何识别AI生成的内容？

我的观点：

2026年，深度伪造技术已经达到了令人惊叹的水平——普通用户用手机APP就能生成以假乱真的视频。但好消息是，检测技术也在同步进步。现在的问题不再是"能不能分辨"，而是"如何建立信任体系"。

2025年的新案例

2025年，一个"名人道歉视频"在社交媒体上疯传：

某明星公开承认"偷税漏税"！

这个视频做得非常逼真，连明星本人的团队都差点信了。

这就是2026年的深度伪造：

不仅视觉上以假乱真，甚至能模仿人的语气、表情、微表情。如果不是明星本人及时出面澄清，后果不堪设想。

1

什么是深度伪造？

深度伪造（Deepfake）是用AI生成或修改的视频、音频、图像，看起来非常逼真。

常见的深度伪造类型：

1.

换脸

：把A的脸换到B的视频上

2.

配音

：生成某人的声音说任意的话

3.

生成视频

：完全生成一个不存在的人的视频

4.

篡改内容

：修改现有视频的内容

5.

文本生成

：模仿某人的写作风格

现在的技术已经可以做到让你看不出真假了。

2

深度伪造的风险

深度伪造的风险比你想象的更严重：

深度伪造的主要风险：

1.

政治风险

：伪造政要讲话、制造谣言

2.

金融诈骗

：伪造老板声音让财务转账

3.

名誉损害

：伪造他人不雅视频

4.

证据伪造

：在法庭上伪造证据

5.

信任崩塌

："看到的听到的都可能是假的"

领域

风险场景

真实案例

金融

用伪造声音诈骗转账

已有多起金额百万以上的案例

政治

伪造选举相关内容

多国选举已出现伪造视频

个人

伪造他人视频敲诈

已出现多起敲诈案例

司法

伪造证据、证词

已有法庭受理相关案件

3

如何识别深度伪造？

虽然很难，但还是有一些线索：

识别技巧：

1.

眼睛

：眨眼不自然、眼睛对不上

2.

面部细节

：边缘模糊、皮肤纹理不自然

3.

音频同步

：口型和声音对不上

4.

背景

：背景光影不自然

5.

常识判断

：内容太离谱，可能是假的

6.

多个来源

：交叉验证，只看一个来源可能被骗

最简单的识别方法：常识

如果一个视频让你觉得"太离谱了"——政要说奇怪的话、名人说完全不符合他风格的话——先别急着信，多等一等，看看多个来源的消息。

大多数深度伪造在内容上都会有破绽，因为伪造者只关注"看起来像"，而不关注"逻辑上合理"。

4

技术防护方法

除了人工识别，技术上也在发展防护：

技术防护手段：

1.

数字水印

：在真实内容上加水印，AI生成的没有

2.

检测工具

：用AI检测AI生成的内容

3.

区块链认证

：记录内容的来源和修改历史

4.

多因素验证

：关键操作需要多种验证方式

但这些技术都不是完美的，道高一尺魔高一丈。

4

2026年的深度伪造检测技术：深度解析

好消息是，检测技术也在同步进步：

AI检测AI：最常用的方法

原理：

训练专门的AI模型来检测深度伪造。

方法：

- 分析面部特征：检测不自然的眨眼模式、面部对称性异常
- 分析纹理：检测合成图像的纹理伪影
- 分析频率域：深度伪造在频域上有特征模式
- 分析时序一致性：检测视频帧之间的不连续性

技术细节：

常用的模型架构包括CNN、Transformer、ViT等。2026年最先进的检测模型准确率已经超过99.5%。

数字水印：内容认证的新标准

原理：

在真实内容中嵌入不可见的数字水印。

类型：

- 可见水印：直接显示在内容上

- 不可见水印：嵌入在像素数据中，肉眼看不见
- 区块链水印：将水印记录在区块链上，不可篡改

技术细节：

2026年，YouTube、TikTok、微信等主流平台都已支持不可见水印标准。

区块链认证：来源验证

原理：

使用区块链技术记录内容的来源和修改历史。

应用：

- 新闻媒体：验证新闻的真实性和来源
- 司法证据：确保证据未被篡改
- 数字资产：验证数字艺术品的真伪

技术细节：

常用的方案包括NFT、零知识证明等。

5

深度伪造的正面用途

不是所有深度伪造都是坏的：

正面应用：

1.

影视特效

：让演员变年轻、变老，或者让去世的演员"复活"

2.

教育

：历史人物"亲自"讲课

3.

accessibility

：让语言障碍者用自己的声音说话

4.

娱乐

：生成有趣的内容

5.

保护隐私

：用虚拟形象代替真实形象

技术只是工具，关键看怎么用。

6

总结：2026年的深度伪造

核心结论：

1. 2026年，深度伪造技术已经非常成熟，难以用肉眼分辨
2. 但检测技术也在进步，平台已经内置检测功能
3. 关键是建立"信任体系"：来源认证、数字水印、区块链
4. 保持警惕，但不必恐慌——技术在博弈中进步
5. 技术本身中性，关键在于使用的人

未来，我们可能会生活在一个"眼见不一定为实"的时代。学会怀疑，学会验证，这可能是最重要的技能。

系列一：AI安全与伦理系列

01 · AI幻觉：为什么AI会“胡说八道”？

02 · 数据隐私：你的对话被用来训练了吗？

03 · AI偏见：算法歧视是怎么产生的？

04 · 深度伪造：如何识别AI生成的内容？ ← 你在这里

05 · AI安全：对抗攻击与防御

06 · 伦理困境：AI决策的责任归属

系列总结

5. AI安全与伦理系列 05

AI安全与伦理系列 05 · AI安全

AI安全与伦理系列 05

系列一

AI安全：对抗攻击与防御

我的观点：

2026年，对抗攻击的威胁依然存在，但防御技术已经有了很大进步。主流AI服务现在都内置了对抗攻击检测和防御机制。对抗攻击不再是致命威胁，但仍然是需要关注的安全问题。

2025年的真实案例

研究人员测试了2025年主流的自动驾驶系统：

在交通标志上贴特制贴纸

老系统：识别错误！

新系统：成功识别！

为什么新系统能成功？

因为2025年的自动驾驶系统已经内置了对抗攻击防御机制。

它们会检测输入中的异常模式，并进行预处理来消除对抗噪声。这就是技术进步的力量。

1

什么是对抗攻击？

对抗攻击是指通过在输入上添加精心设计的微小扰动，让AI模型产生错误的输出。

对抗攻击的特点：

1.

人类不可见

：噪声微小到人类看不见

2.

针对性强

：专门让AI犯特定错误

3.

泛化性

：可能在物理世界也有效

4.

难以防御

：很难完全避免

真实案例：停车标志攻击

研究人员在停车标志上贴了几个小贴纸。

人类看：还是停车标志！

自动驾驶汽车看：限速45公里！

这可能会导致严重的交通事故！

2

对抗攻击的类型

常见的对抗攻击有这几种：

类型

目标

示例

白盒攻击

知道模型结构和参数

研究人员攻击自己的模型

黑盒攻击

不知道模型内部信息

攻击者只能查询API

有目标攻击

让AI输出特定错误结果

让熊猫被识别为长臂猿

无目标攻击

只要AI出错就行

让AI认不出任何东西

物理攻击

在真实世界里的攻击

在停车标志上贴贴纸

3

真实世界的风险

对抗攻击不只是实验室里的玩具，在真实世界里有严重风险：

真实世界风险场景：

1.

自动驾驶

：让汽车看错交通标志

2.

安防系统

：让面部识别认不出人，或者认错人

3.

垃圾邮件过滤

：让垃圾邮件绕过检测

4.

医疗诊断

：让AI看错医疗影像

5.

金融欺诈

：让风控系统漏掉欺诈

每一个场景都可能造成严重损失。

4

为什么会有对抗攻击？

这是深度学习的一个基本特性：

原因分析：

1.

高维空间

：神经网络在极高维空间里工作，有很多"脆弱"的方向

2.

线性假设

：很多攻击利用了神经网络的局部线性特性

3.

过拟合

：模型可能学到了虚假的特征

4.

缺少鲁棒性

：模型没有训练过对抗样本

简单说：神经网络的工作方式和人类视觉系统不一样。

5

2026年的对抗攻击防御技术：深度解析

2026年，防御技术已经相当成熟：

对抗训练：最有效的防御方法

原理：

在训练过程中加入对抗样本，让模型学习如何应对攻击。

方法：

- FGSM（快速梯度符号法）：计算损失函数对输入的梯度，沿梯度方向添加噪声

- PGD（投影梯度下降）：迭代优化对抗扰动
- TRADES：在训练时同时优化准确率和鲁棒性

技术细节：

2026年，对抗训练已经成为大多数AI系统训练流程的标准环节。

输入净化：去除对抗噪声

原理：

在输入进入模型之前，先检测并去除对抗扰动。

方法：

- 降噪自编码器：训练一个自动编码器来还原干净的输入
- 随机化：对输入进行随机变换，破坏对抗噪声
- 特征挤压：减少输入的精度或颜色通道

技术细节：

输入净化可以作为防御的第一道防线，但可能会影响模型的准确率。

自适应防御：动态调整策略

原理：

根据检测到的攻击类型，动态调整防御策略。

方法：

- 攻击检测：使用专门的模型检测是否受到攻击
- 模型切换：根据攻击类型切换到更鲁棒的模型
- 动态参数调整：实时调整模型的超参数

技术细节：

自适应防御需要实时监控和快速响应能力。

现在大多数生产环境的AI系统都已经内置了这些防御机制。

6

深度思考：安全的AI

对抗攻击让我们思考一个更深的问题：

什么是"安全的"AI？

AI不仅要在正常情况下工作，还要在有人故意攻击的情况下也能正常工作。

就像传统的网络安全一样，AI系统也需要"安全设计"。

这不仅是技术问题，也是工程问题——我们需要像设计安全软件那样设计AI系统。

7

总结：2026年的AI安全

核心结论：

1. 2026年，对抗攻击的威胁依然存在，但防御技术已经成熟
2. 主流AI服务都内置了对抗攻击检测和防御机制
3. 对抗训练已经成为标准训练流程
4. AI系统需要像传统软件那样考安全问题
5. 安全是持续的过程，不是一次性的解决方案

系列一：AI安全与伦理系列

- 01 · AI幻觉：为什么AI会“胡说八道”？
- 02 · 数据隐私：你的对话被用来训练了吗？
- 03 · AI偏见：算法歧视是怎么产生的？
- 04 · 深度伪造：如何识别AI生成的内容？
- 05 · AI安全：对抗攻击与防御 ← 你在这里
- 06 · 伦理困境：AI决策的责任归属

系列总结

6. AI安全与伦理系列 06

AI安全与伦理系列 06 · 伦理困境

AI安全与伦理系列 06

系列一

伦理困境：AI决策的责任归属

我的观点：

2026年，AI决策的责任归属问题已经有了一些进展——很多国家已经开始制定AI责任相关的法律。但这仍然是一个复杂的问题，需要技术、法律和伦理的共同努力。关键不是让AI负责，而是确保人类保持对AI决策的最终控制权。

一个经典的思想实验

自动驾驶汽车遇到一个困境：

要么撞向一个行人，要么撞墙牺牲乘客。

AI应该怎么选？

更重要的是：如果AI做了选择，导致有人伤亡，

谁来负责

？

是程序员？是公司？是车主？还是AI自己？

1

AI决策的责任困境

当AI代替人做决策时，责任就变得模糊了：

责任的三个层面：

1.

技术层面

：谁写的代码？谁训练的模型？

2.

公司层面

：谁部署的AI？谁从中受益？

3.

用户层面

：谁使用AI做出了决定？

问题是：这三方可能都有责任，但法律还没有明确划分。

2025年案例：AI医疗诊断失误

2025年，一名患者因AI诊断错误延误了治疗。

法院判决：医院承担主要责任，因为医生没有对AI的诊断进行复核。

这个案例确立了一个原则：AI只是辅助工具，最终责任仍然在人类身上。

2

常见的责任困境场景

AI决策的责任问题出现在很多领域：

领域

场景

责任问题

医疗

AI诊断错误

医生还是AI公司负责？

法律

AI量刑建议

法官还是AI承担责任？

金融

AI投资亏损

投资者还是公司负责？

教育

AI推荐专业选错

学生还是AI负责？

3

2026年的责任归属实践：深度解析

2026年，关于AI责任归属已经有了一些共识：

人类最终责任原则

核心原则：

AI只是工具，人类保持最终控制权。

法律基础：

2025年的多个案例都确立了这一原则。当AI做出错误决策时，最终责任在使用AI的人类身上。

实践应用：

在医疗领域，医生必须对AI的诊断进行复核；在金融领域，投资顾问必须对AI的推荐进行审核。

分层责任体系

开发者责任：

确保模型的安全性和可靠性，提供文档说明模型的局限性

部署者责任：

确保AI系统在正确的场景下使用，建立适当的监控机制

使用者责任：

正确使用AI，对最终决策负责

技术细节：

很多公司已经开始购买AI责任保险，以应对可能的法律风险。

4

透明度与可解释性：技术深度

一个更大的问题：很多AI决策是"黑盒子"，我们不知道它为什么做出那个决定。

可解释AI（XAI）

如果AI说"我建议拒绝你的贷款申请"，你有权知道"为什么"。

是因为你的职业？你的收入？还是你的地址？

可解释AI就是要解决这个问题：让AI的决策过程透明化。

欧盟的GDPR已经规定了"解释权"——用户有权知道AI为什么做出影响他们的决定。

5

深度思考：人的位置

这是一个更深层次的问题：

我们应该让AI做什么决定？

也许问题不是"谁来负责"，而是"我们应该让AI做哪些决定"。

是不是有些决定，不管AI多准确，都应该保留给人来做？

比如：判多少年刑？是否批准贷款？谁能上大学？

我的看法：AI可以提建议，但重大决定必须由人来拍板，同时承担责任。

6

总结：2026年的AI伦理

核心结论：

1. 2026年，AI责任归属问题已经有了一些法律框架
2. 核心原则：人类保持最终控制权和责任
3. AI决策需要透明和可解释
4. 重大决定应该保留给人来做
5. AI是工具，关键在于如何使用它

这个系列写完了。我们讨论了AI幻觉、数据隐私、算法偏见、深度伪造、对抗攻击、伦理困境。

2026年的AI已经不是三年前那个容易犯错的"愣头青"了。它变得更聪明、更可靠，但它仍然是工具。我们需要学会与它共处——利用它的能力，同时保持警惕。

系列一：AI安全与伦理系列

01 · AI幻觉：为什么AI会“胡说八道”？

02 · 数据隐私：你的对话被用来训练了吗？

03 · AI偏见：算法歧视是怎么产生的？

04 · 深度伪造：如何识别AI生成的内容？

05 · AI安全：对抗攻击与防御

06 · 伦理困境：AI决策的责任归属 ← 你在这里

系列总结

7. AI安全与伦理系列 · 总结

AI安全与伦理系列 · 总结

AI安全与伦理系列 · 总结

系列总结

2026年6月 | 理解AI时代的安全与伦理挑战

核心观点：

2026年，AI技术已经取得了巨大进步，但安全与伦理问题依然存在，只是形式变得更加隐蔽。我们需要学会与AI共处——利用它的能力，同时保持警惕。

1

AI幻觉：为什么AI会“胡说八道”？

核心观点

2026年，简单的事实错误已经很少见，但幻觉变得更隐蔽——表现为细节编造、逻辑跳跃、虚假权威等形式。

技术根源：

Transformer本质上是预测下一个token，而非真正“理解”事实

关键技术：

RAG（检索增强生成）、CoT（思考链）已成为标配

实用建议：

对关键信息进行交叉验证，关注AI的不确定性表达

2

数据隐私：你的对话被用来训练了吗？

核心观点

主流服务已默认不使用用户数据训练模型，但新的隐私风险在出现。

新风险：

模型记忆、向量数据库泄露、第三方插件数据收集

防护技术：

差分隐私、联邦学习、同态加密

用户行动：

检查隐私设置、使用无痕模式、数据脱敏

3

AI偏见：算法歧视是怎么产生的？

核心观点

明显的偏见已很少见，但微妙的、间接的偏见依然存在。

偏见来源：

训练数据中的社会偏见被AI放大

缓解技术：

去偏数据预处理、公平约束训练、偏见检测工具

公平定义：

结果公平、机会公平、过程公平三者难以同时满足

4

深度伪造：如何识别AI生成的内容？

核心观点

深度伪造技术越来越成熟，但检测技术也在同步进步。

主要风险：

政治操纵、金融诈骗、名誉损害、证据伪造

检测技术：

AI检测AI（准确率>99.5%）、数字水印、区块链认证

正面用途：

影视制作、历史修复、教育模拟

5

AI安全：对抗攻击与防御

核心观点

对抗攻击是深度学习的基本特性，但2026年防御技术已相当成熟。

攻击类型：

白盒攻击、黑盒攻击、物理攻击

防御技术：

对抗训练（FGSM/PGD/TRADES）、输入净化、自适应防御

真实风险：

自动驾驶、安防系统、医疗诊断

6

伦理困境：AI决策的责任归属

核心观点

法律框架已确立"人类最终责任"原则，AI只是辅助工具。

责任原则：

人类保持最终控制权和责任

分层责任：

开发者→部署者→使用者

关键问题：

有些决定应该保留给人类来做

2026年AI安全与伦理现状总结：

进步：

简单的事实错误、数据滥用、明显歧视等问题已大幅改善。

挑战：

新的风险在出现——更隐蔽的幻觉、模型记忆、微妙的偏见。

技术：

防御技术在同步进步，大多数问题都有成熟的解决方案。

伦理：

责任归属已有法律框架，核心原则是"人类保持最终控制权"。

最终思考：与AI共处

2026年的AI已经不是三年前那个容易犯错的"愣头青"了。它变得更聪明、更可靠，但它仍然是工具。

我们需要学会与AI共处：利用它的能力来提高效率、解决问题，同时保持警惕——关注它的局限性，理解它的风险，在关键问题上保留人类的判断。

AI的安全与伦理，本质上是人的问题。技术本身没有善恶，关键在于我们如何使用它。

系列一：AI安全与伦理系列

01 · AI幻觉：为什么AI会“胡说八道”？

02 · 数据隐私：你的对话被用来训练了吗？

03 · AI偏见：算法歧视是怎么产生的？

04 · 深度伪造：如何识别AI生成的内容？

05 · AI安全：对抗攻击与防御

06 · 伦理困境：AI决策的责任归属

你在这里：系列总结